

MVP

MINIMUM VIABLE PRODUCT

Apresentação, requisitos e critérios de avaliação do trabalho final

Item	Descrição
Instituição	Universidade de Brasília (UnB)
Unidade	Departamento de Engenharia de Produção
Professor responsável	André Luiz Marques Serrano
Natureza do trabalho	Individual
Produto esperado	Pipeline de dados em nuvem, documentado em repositório público do GitHub
Pontuação total	10,0 pontos

Sumário

1. Apresentação

- 1.1 Inovação ·
- 1.2 Projetos inovadores ·
- 1.3 Benefícios ·
- 1.4 Ciclo de experimentação ·
- 1.5 Etapas

2. Requisitos para o desenvolvimento do MVP

- 2.1 Descrição ·
- 2.2 Objetivo ·
- 2.3 Plataforma

3. Detalhamento das etapas

- 3.1 Busca ·
- 3.2 Coleta ·
- 3.3 Modelagem ·
- 3.4 Carga ·
- 3.5 Análise

4. Ética, licenciamento e proteção de dados

5. Entrega

- 5.1 Repositório ·
- 5.2 Evidências ·
- 5.3 Postagem

6. Autoavaliação

7. Critérios de avaliação

8. Checklist de entrega

9. Marcos de acompanhamento

Apêndice A — Glossário

1. Apresentação

1.1 Inovação

Com o avanço tecnológico, a inovação passou a fazer parte do nosso dia a dia. Pensando nisso, o Departamento de Engenharia de Produção da Universidade de Brasília incorporou ao aprendizado a experimentação por meio do desenvolvimento do *minimum viable product* (MVP).

O propósito é preparar você para desenvolver uma solução e testá-la junto às necessidades reais de seus usuários, construindo uma versão estritamente suficiente para cumprir sua função — nem mais, nem menos. O MVP não é um produto incompleto: é a menor versão capaz de gerar aprendizado válido sobre uma hipótese de negócio.

O que distingue um MVP de um protótipo qualquer

O protótipo demonstra que algo pode ser construído. O MVP verifica se algo deve ser construído. A diferença está na existência de uma hipótese explícita e de uma métrica que a confirme ou refute.

1.2 Projetos inovadores

Um projeto inovador nasce na interseção de três dimensões. O MVP é justamente o instrumento que permite verificar, com baixo custo e em pouco tempo, se essa interseção de fato existe:

Dimensão	Pergunta central	Evidência esperada no MVP
Viabilidade técnica	A solução pode ser construída com a tecnologia disponível?	Pipeline funcionando ponta a ponta na plataforma de nuvem escolhida
Viabilidade financeira	A solução é economicamente sustentável?	Uso de recursos compatível com o problema; custo de operação estimado
Desejabilidade	A solução é o que os usuários de fato querem?	Perguntas de negócio respondidas com dados e discutidas criticamente

O MVP é o ponto em que as três dimensões se encontram. Um trabalho que atende apenas à dimensão técnica entrega código que ninguém pediu.

1.3 Benefícios de desenvolver um MVP

- Testar uma ideia com poucos recursos, antes de comprometer investimento relevante.
- Verificar tendências de mercado e validar a existência da demanda.
- Lançar produtos mais rapidamente, reduzindo o tempo até o primeiro aprendizado.
- Atrair investidores e parceiros com evidência empírica, e não apenas com a intenção.

1.4 O ciclo de experimentação

O MVP é a peça central de uma estratégia de experimentação. Para isso, você deve desenvolver uma solução real com base nos conhecimentos adquiridos ao longo da disciplina. O ciclo se organiza em torno de uma solução para uma necessidade real:

Etapa	O que acontece	No contexto deste trabalho
Ideia	Formulação da hipótese	Definição do problema e das perguntas de negócio
Construir	Construção do menor experimento válido	Coleta, modelagem e carga dos dados na nuvem
Produto	Versão mínima em operação	Pipeline executável e repositório publicado
Medir	Observação instrumentada	Consultas e análises sobre os dados carregados
Dados	Resultado bruto do experimento	Métricas, tabelas e visualizações obtidas
Aprender	Interpretação e decisão	Discussão dos resultados e autoavaliação

Cada volta no ciclo deve gerar aprendizado validado por evidência, e não apenas incremento de funcionalidades.

1.5 Etapas para o desenvolvimento do MVP

- **Ideia.** Qual será a principal funcionalidade do MVP?
- **Estrutura.** Que ferramentas serão utilizadas para o desenvolvimento?
- **Protótipo.** Entrega do protótipo final, acompanhado de sua documentação.

2. Requisitos para o Desenvolvimento do MVP

2.1 Descrição

Neste trabalho, você deverá ser capaz de construir um pipeline de dados utilizando tecnologias na nuvem. O pipeline irá envolver a busca, a coleta, a modelagem, a carga e a análise dos dados.

2.2 Objetivo

Comece pelo objetivo do seu trabalho. Antes de iniciar sua busca pelos dados, pense e descreva claramente qual problema deseja resolver com este MVP. Enumere as perguntas que deseja responder.

Atenção

É de extrema importância que esta etapa seja feita antes de iniciar qualquer outra. Escolher primeiro a base de dados e só depois inventar o problema produz trabalhos descritivos, sem tese, e é o erro mais frequente nesta disciplina.

Uma vez traçado o objetivo, conhecendo bem qual problema se deseja resolver e quais perguntas se deseja responder, é hora de iniciar a busca pelos dados.

Não é necessário atingir todos os objetivos desenhados nesta seção. Assim, não remova perguntas às quais não se conseguiu responder. Deixe a documentação do objetivo intacta e faça uma boa discussão do atingimento deste ao final do trabalho (vide Autoavaliação).

Como formular boas perguntas de negócio

Uma pergunta de negócio bem construída é específica, verificável com os dados disponíveis e ligada a uma decisão. Compare:

Formulação frágil	Formulação adequada
Como são os dados de acidentes de trabalho?	Quais setores concentram os afastamentos mais longos e como isso evoluiu nos últimos cinco anos?
Analisar o consumo de energia.	Em que faixas horárias o consumo excede a demanda contratada e qual o custo associado?
Estudar atrasos de entrega.	Qual a relação entre distância percorrida, modal e probabilidade de atraso superior a 48 horas?

Recomenda-se de três a seis perguntas. Poucas perguntas empobrecem a análise; muitas dispersam o esforço e produzem respostas rasas.

2.3 Plataforma

Vamos direcionar os esforços de apoio na Plataforma Databricks, que possui uma versão de uso gratuito, com limitação na qualidade e na quantidade de máquinas do cluster.

Não haverá limitação quanto à utilização de outras plataformas de dados e provedores de nuvem. Todos os trabalhos, em qualquer plataforma escolhida pelo aluno, serão devidamente avaliados. Entretanto,

conforme dito acima, nossos esforços de suporte estarão voltados para a solução de problemas dos alunos na Plataforma Databricks.

Seja qual for a escolha, o requisito é o mesmo: os dados devem estar efetivamente persistidos na nuvem ao final do trabalho, e isso deve ser demonstrável.

3. Detalhamento das etapas

3.1 Busca pelos dados

Escolha uma base de dados para utilizar em seu MVP de forma que se possa atingir os objetivos traçados na etapa anterior.

Há inúmeras bases de dados gratuitas disponíveis na web, por exemplo:

- Portal Brasileiro de Dados Abertos — <https://dados.gov.br/>
- Portal da Transparência — <https://portaldatransparencia.gov.br/>
- IBGE / SIDRA — <https://sidra.ibge.gov.br/>
- Google Cloud Public Datasets — <https://cloud.google.com/datasets>
- Kaggle — <https://www.kaggle.com/datasets>
- IMDB — <https://datasets.imdbws.com/>
- Tableau (bases públicas) — <https://www.tableau.com/learn/articles/free-public-data-sets>
- Stanford Large Network Dataset Collection — <https://snap.stanford.edu/data/index.html>
- Yelp Open Dataset — <https://www.yelp.ca/dataset>

As bases de dados abertas disponíveis para o MVP serão discutidas no fórum da disciplina, onde montaremos colaborativamente um repositório de possibilidades.

Caso haja uma licença de uso para o conjunto de dados escolhido, isto deve constar na documentação do MVP.

3.2 Coleta

Uma vez definido o conjunto de dados, devemos coletá-lo e armazená-lo na nuvem.

É possível que, a partir de sua escolha do conjunto de dados, seja necessária uma etapa de construção de robôs de coleta, e.g. via *web scraping*. Neste caso, atente-se às questões éticas e aos termos de uso quanto à possibilidade de utilizar robôs de coleta de informação nos sites escolhidos.

Caso tenha optado por utilizar um conjunto de dados real da empresa onde trabalha, tenha bastante cuidado com a confidencialidade destes dados e/ou das análises que serão feitas em sequência.

Documente a data da coleta, o volume obtido e o formato original dos arquivos. Essa informação é parte da reprodutibilidade do trabalho.

3.3 Modelagem

Você deve construir um modelo de dados em Esquema Estrela ou Snowflake, como em um Data Warehouse, ou flat por cada conceito, como em um Data Lake.

Independentemente do modelo, deve ser construído um Catálogo de Dados contendo minimamente uma descrição detalhada dos dados e de seus domínios, com valores mínimos e máximos esperados para dados numéricos e as possíveis categorias para dados categóricos.

Este modelo deve também descrever a linhagem dos dados: de onde foram baixados e qual técnica foi utilizada para compor o conjunto de dados, caso haja.

Conteúdo mínimo do Catálogo de Dados

Campo	Descrição
Nome do atributo	Identificador do campo na tabela final
Tipo	Numérico, categórico, texto, data, booleano
Descrição	O que o atributo representa no domínio do problema
Domínio	Faixa mínima e máxima esperada, ou lista de categorias válidas
Obrigatoriedade	Se admite valores nulos e o que a ausência significa
Linhagem	Origem, data de extração e transformações aplicadas

3.4 Carga

Nesta etapa, será feita a carga dos dados para o Data Warehouse/Data Lake. Na avaliação desta etapa, será dado valor à utilização de pipelines de ETL (Extração, Transformação e Carga) na plataforma de dados utilizada. Pipelines de ETL na Plataforma Databricks serão discutidos nos encontros síncronos e no fórum da disciplina.

Deve-se documentar os processos de transformação e carga, principalmente os de transformação, e.g. a junção e a conciliação de dois conjuntos de dados diferentes. Regras de negócio aplicadas na transformação — conversões de unidade, deduplicação, padronização de chaves — precisam estar explícitas, pois afetam diretamente a interpretação dos resultados.

3.5 Análise

Vamos dividir a etapa de análise em duas: qualidade de dados e solução do problema.

a) Qualidade de dados

Deve ser feita uma análise da qualidade para cada atributo do conjunto de dados. Existem problemas no conjunto de dados? Caso haja, como esses problemas podem ser resolvidos para que não afetem as respostas das perguntas que se quer solucionar?

É possível que não se encontrem problemas nos conjuntos de dados; em alguns casos, há conjuntos curados e já bem tratados antes de serem disponibilizados. Entretanto, mesmo nestes casos, espera-se que seja feita uma análise de valores por atributo e que se demonstre que não foram encontrados problemas.

Dimensões usualmente examinadas: completude (nulos e ausências), unicidade (duplicatas), consistência (contradições entre atributos), conformidade (aderência ao domínio declarado), acurácia (valores implausíveis) e atualidade.

b) Solução do problema

Chegou o momento de solucionar o problema em questão, definido preliminarmente nos objetivos. Deve-se buscar respostas para as perguntas elencadas. Para cada resposta obtida tecnicamente por meio da análise dos dados, deve haver uma discussão do seu resultado, conectando os números obtidos às respostas do problema a ser solucionado.

Ao final, deve haver uma discussão geral sobre a solução do problema a partir das discussões de cada resposta. Resultados negativos ou inconclusivos são legítimos e devem ser relatados: o que se avalia é o rigor do raciocínio, não a conveniência do achado.

Aqui, podem ser utilizadas bibliotecas Python vistas nas disciplinas de análise exploratória e pré-processamento de dados, ou as ferramentas vistas em visualização da informação. Entretanto, caso ainda não tenha cursado estas disciplinas, é possível responder às perguntas do objetivo somente por meio da linguagem SQL, objeto da disciplina de Banco de Dados, ou por meio da linguagem de consulta do banco NoSQL escolhido, objeto da disciplina de Data Warehouse.

4. Ética, licenciamento e proteção de dados

O trabalho deve observar as condições de uso dos dados empregados. Três pontos merecem atenção explícita na documentação:

1. **Licença.** Registre a licença do conjunto de dados e o que ela autoriza quanto a redistribuição e uso derivado. Se a licença não permitir republicação, não versione os dados brutos no repositório: publique o script de coleta.
2. **Dados pessoais.** Conjuntos que contenham dados pessoais exigem cuidado adicional em razão da Lei nº 13.709/2018 (LGPD). Prefira bases anonimizadas ou agregadas; havendo identificadores diretos, aplique anonimização antes da carga e descreva o procedimento.
3. **Dados corporativos.** Ao utilizar dados da empresa onde trabalha, obtenha autorização, descaracterize o que for sensível e avalie se as conclusões podem ser divulgadas em repositório público.

Na dúvida entre uma base mais rica com restrição de uso e uma base mais simples e aberta, opte pela segunda. O objetivo do MVP é o método, não o ineditismo do dado.

5. Entrega

5.1 Repositório

Deverá ser disponibilizado todo o código construído em um repositório público do GitHub. Se tiver dúvidas sobre como criar um repositório público, consulte:

<https://docs.github.com/pt/repositories/creating-and-managing-repositories/creating-a-new-repository>

Sugere-se a organização abaixo, que facilita a leitura por terceiros e a própria avaliação:

Caminho	Conteúdo
README.md	Documento principal: objetivo, perguntas, metodologia, resultados e autoavaliação
/notebooks	Notebooks de coleta, transformação, carga e análise
/scripts	Código auxiliar, rotinas de ETL e de coleta
/catalogo	Catálogo de Dados e diagrama do modelo (estrela, snowflake ou flat)
/evidencias	Capturas de tela e vídeos que comprovam a execução na nuvem
LICENSE	Licença do código e registro da licença dos dados utilizados

O README é o documento avaliado. Espera-se que alguém sem contexto prévio consiga, apenas lendo-o, entender o problema, reproduzir o pipeline e interpretar os resultados.

5.2 Evidências

Algumas tarefas das etapas do trabalho podem ser feitas a partir de componentes visuais da plataforma de nuvem. Desta forma, deve-se gerar evidência da execução destes passos por meio de *screenshots* ou vídeos.

Deve-se igualmente gerar evidência dos resultados das respostas às perguntas que definem o problema do MVP, por meio de *screenshots* ou vídeos. As imagens devem estar legíveis e referenciadas no ponto do texto em que sustentam a afirmação.

5.3 Postagem

A entrega oficial do MVP será realizada no fórum de entrega da disciplina, no ambiente virtual de aprendizagem, onde é necessário compartilhar o link do repositório do GitHub. Caso haja material complementar, ele poderá ser postado como anexo na mesma resposta.

Será permitido o envio de até duas respostas nesse fórum, caso haja algum erro na primeira. Certifique-se de que todas as informações estejam entregues corretamente e de que o repositório esteja efetivamente público. Em caso de dúvida, procure o professor responsável pela disciplina.

6. Autoavaliação

Ao finalizar o trabalho, é esperado que o aluno faça uma autoavaliação contendo uma discussão sobre se conseguiu atingir os objetivos delineados antes do início das outras etapas, as dificuldades encontradas na execução do trabalho, bem como os trabalhos futuros para enriquecer o problema e sua solução em seu portfólio. Sugere-se organizá-la em torno das seguintes questões:

4. Quais das perguntas de negócio formuladas no objetivo foram respondidas e quais não foram? Por quê?
5. Que limitações dos dados condicionaram os resultados obtidos?
6. Quais decisões técnicas você tomaria de outra forma se recomeçasse o trabalho?
7. Que extensões seriam necessárias para transformar este MVP em uma solução de uso contínuo?

7. Critérios de avaliação

Critério	Pontuação	O que será avaliado
Objetivo	1,0 pt	O objetivo deve ser muito bem detalhado; é um planejamento do trabalho, contendo de forma clara e objetiva o problema a ser resolvido e as perguntas de negócio a serem respondidas. Avalia-se a qualidade desta descrição.
Coleta	0,5 pt	Documentação sobre a coleta dos conjuntos de dados e a persistência dos mesmos na plataforma de nuvem.
Modelagem	2,0 pt	Qualidade da modelagem dos dados (1,0 pt) e documentação do Catálogo de Dados, incluindo domínios e linhagem (1,0 pt).
Carga	1,0 pt	Qualidade da documentação da carga, uso de pipelines de ETL, correteude e persistência dos dados na nuvem após a carga.
Análise	3,0 pt	Análise de qualidade dos dados (1,0 pt), solução correta do problema (1,0 pt) e discussão consistente a partir das respostas obtidas (1,0 pt).
Autoavaliação	0,5 pt	Discussão pertinente sobre o atingimento dos objetivos traçados no início do trabalho, dificuldades e trabalhos futuros.
Capricho	2,0 pt	Capricho e qualidade geral do trabalho como um todo, avaliados de forma subjetiva: clareza da redação, organização do repositório e apresentação dos resultados.
Total	10,0 pt	—

Sobre o critério Capricho

Os dois pontos reservados ao capricho não são um bônus de cortesia. Trabalhos tecnicamente corretos, porém mal documentados, com gráficos ilegíveis ou repositório desorganizado, perdem pontuação aqui — e é onde a maior parte da diferença entre trabalhos se manifesta.

8. Checklist de entrega

Antes de postar, verifique:

- ☐ O objetivo e as perguntas de negócio estão documentados e permanecem íntegros, inclusive os não atingidos.
- ☐ A origem, a licença e a data de coleta do conjunto de dados estão registradas.
- ☐ Os dados estão efetivamente persistidos na plataforma de nuvem.
- ☐ O modelo de dados está descrito e o Catálogo de Dados contempla domínios e linhagem.
- ☐ Os processos de transformação e carga estão documentados, com as regras de negócio explícitas.

- ☐ A análise de qualidade cobre todos os atributos relevantes.
- ☐ Cada pergunta de negócio tem resposta com evidência e discussão associada.
- ☐ Há discussão geral conectando as respostas à solução do problema.
- ☐ A autoavaliação está presente e responde às questões sugeridas.
- ☐ As evidências (capturas e vídeos) estão legíveis e referenciadas no texto.
- ☐ O repositório do GitHub está público e o link foi conferido em janela anônima.

9. Marcos de acompanhamento

O acompanhamento do MVP seguirá os marcos abaixo, cujas datas serão divulgadas no ambiente virtual da disciplina:

- Orientação inicial do MVP.
- Encontro sobre transformação de mercado.
- Sessões de dúvidas do MVP, em encontros periódicos ao longo do desenvolvimento.
- Entrega final do MVP.
- Divulgação do resultado final.

Apêndice A — Glossário

Termo	Definição
MVP	Versão mínima de uma solução, suficiente para testar uma hipótese e gerar aprendizado validado.
Pipeline de dados	Sequência automatizada de etapas que move e transforma dados da origem até o destino analítico.
ETL	Extração, Transformação e Carga: padrão de processamento em que os dados são transformados antes da carga.
Data Warehouse	Repositório analítico com dados estruturados e modelados para consulta.
Data Lake	Repositório que armazena dados em formato bruto ou pouco estruturado, organizados por conceito.
Esquema Estrela	Modelo dimensional com uma tabela fato central ligada a tabelas de dimensão desnormalizadas.
Snowflake	Variante do esquema estrela em que as dimensões são normalizadas em hierarquias.
Catálogo de Dados	Documento que descreve atributos, tipos, domínios, significado e origem dos dados.
Linhagem	Registro da procedência dos dados e das transformações sofridas ao longo do pipeline.
Web scraping	Coleta automatizada de dados publicados em páginas web, sujeita aos termos de uso do site.